

UNIVERSIDADE PRESBITERIANA MACKENZIE

FACULDADE DE COMPUTAÇÃO E INFORMÁTICA

SISTEMA DE RECOMENDAÇÃO DE PRODUTOS PARA E-COMMERCE: UMA ABORDAGEM BASEADA EM FILTRAGEM COLABORATIVA PARA AMPLIAR A VISIBILIDADE DE PEQUENOS VENDEDORES

Luana Isabella Xavier Porto – RA 10443026

Jaques Eler Antunes – RA 10748092

Felipe Barreto – RA 10742390

Gabrielle Solange Ferreira – RA 10414956

São Paulo

2026

SUMÁRIO

1 INTRODUÇÃO.....	3
1.1 Motivação e Justificativa	3
1.2 Objetivos.....	4
1.3 Base de Dados	4
2 CRONOGRAMA DO PROJETO	6
3 REFERENCIAL TEÓRICO.....	7
3.1 Sistemas de recomendação	7
3.2 Feedback explícito e feedback implícito	7
3.3 Base de Dados	8
3.4 Fatoração matricial e ALS para feedback implícito	8
3.5 Filtragem baseada em conteúdo	8
3.6 Sistemas híbridos.....	9
3.7 Desafios: esparsidade, partida-fria e viés de popularidade.....	9
3.8 Avaliação de sistemas de recomendação.....	9
3.9 Equidade e exposição de vendedores	10
3.10 Bibliotecas Python utilizadas.....	10
REFERÊNCIAS	11

1 INTRODUÇÃO

O comércio eletrônico consolidou-se, na última década, como um dos principais canais de compra e venda de produtos no Brasil e no mundo. Plataformas como Amazon, Mercado Livre e marketplaces regionais reúnem milhares de vendedores e milhões de itens, criando um cenário em que o consumidor é constantemente exposto a um volume de opções muito superior à sua capacidade de avaliação individual. Nesse contexto, os sistemas de recomendação tornaram-se um componente essencial da experiência de compra digital, atuando como filtros inteligentes capazes de sugerir produtos relevantes a partir do histórico de navegação, das compras anteriores e das avaliações de outros usuários com perfil de consumo semelhante (SCHAFER; KONSTAN; RIEDL, 2001).

Empresas como Amazon, Netflix e Spotify já demonstraram, em larga escala, o impacto positivo de modelos de recomendação baseados em Machine Learning (ML) tanto para a experiência do usuário quanto para os resultados de negócio (KOREN; BELL; VOLINSKY, 2009; RICCI; ROKACH; SHAPIRA, 2022). No entanto, essa mesma tecnologia, quando aplicada de forma indiscriminada, tende a favorecer produtos e vendedores que já possuem grande volume de avaliações e vendas, criando um ciclo de retroalimentação que dificulta a visibilidade de pequenos e médios vendedores recém-inseridos na plataforma.

1.1 Motivação e justificativa

A motivação para o desenvolvimento deste projeto parte da constatação de que grande parte dos vendedores de pequeno porte que atuam em marketplaces de e-commerce enfrenta dificuldade de visibilidade frente a concorrentes maiores, ainda que ofereçam produtos de qualidade equivalente ou superior. Esse problema é especialmente relevante no cenário brasileiro, em que o comércio eletrônico tem sido apontado como uma importante via de geração de renda e formalização de pequenos negócios.

A escolha do tema também se justifica pelo interesse pessoal e profissional do grupo em aplicações práticas de Machine Learning voltadas ao ambiente de negócios, área em que sistemas de recomendação representam um dos casos de uso mais consolidados e, ao mesmo tempo, mais ricos em desafios técnicos, como a esparsidade dos dados de avaliação, o problema da partida-fria (cold-start) para produtos e usuários novos, e a necessidade de equilibrar relevância e diversidade nas recomendações (KOREN; BELL; VOLINSKY, 2009).

Do ponto de vista de relevância acadêmica, o projeto contribui para elevar o nível de conhecimento do grupo sobre técnicas de filtragem colaborativa e de avaliação de modelos de recomendação, além de possibilitar a proposição de abordagens que considerem, junto à acurácia do modelo, critérios de exposição mais equilibrada entre vendedores de diferentes portes.

Sob a ótica extensionista, este trabalho dialoga com os Objetivos de Desenvolvimento Sustentável (ODS) da Organização das Nações Unidas (ONU), em especial o ODS 8 (Trabalho decente e crescimento econômico) e o ODS 9 (Indústria, inovação e infraestrutura), na medida em que propõe uma reflexão sobre como soluções de inteligência artificial podem ser desenhadas para apoiar a inclusão econômica de pequenos empreendedores no ambiente digital, e não apenas otimizar métricas de engajamento e receita (ONU BRASIL, 2023).

1.2 Objetivos

O objetivo geral deste trabalho é desenvolver um sistema de recomendação de produtos para e-commerce, baseado em técnicas de Machine Learning, utilizando dados históricos de pedidos e avaliações de clientes, de modo a sugerir produtos relevantes aos usuários e, simultaneamente, contribuir para uma exposição mais equilibrada de vendedores de diferentes portes na plataforma.

Para alcançar o objetivo geral, foram definidos os seguintes objetivos específicos:

- a) realizar a análise exploratória da base de dados escolhida, identificando suas principais características, limitações e possíveis vieses;
- b) realizar a limpeza e a preparação dos dados para o treinamento do modelo de recomendação;
- c) selecionar e treinar uma técnica de recomendação adequada ao problema proposto, como filtragem colaborativa baseada em avaliações;
- d) definir métricas apropriadas para avaliar o desempenho do modelo desenvolvido;
- e) realizar um treinamento inicial do modelo, a fim de avaliar a adequação da técnica escolhida ao problema e à base de dados selecionada.

1.3 Base de Dados

Para o desenvolvimento do sistema de recomendação, será utilizada a base pública Brazilian E-Commerce Public Dataset by Olist, disponibilizada na plataforma Kaggle (OLIST, 2018). A base reúne dados reais de aproximadamente 100 mil pedidos realizados entre 2016 e 2018 em um marketplace brasileiro, contemplando informações sobre pedidos, produtos, categorias, preços, vendedores, localização geográfica de clientes e vendedores, prazos de entrega e avaliações de clientes (notas de 1 a 5 e comentários textuais).

A escolha dessa base justifica-se por sua abrangência, por refletir o comportamento real de compra no mercado brasileiro e por conter, de forma nativa, informações sobre o porte dos vendedores e sua distribuição geográfica, o que viabiliza a análise do problema de visibilidade proposto como recorte extensionista deste projeto. Os dados possuem acesso público e gratuito, e suas limitações — como o recorte temporal específico e a ausência de dados de navegação do usuário — serão consideradas nas etapas seguintes do projeto, sobretudo na definição do escopo do modelo.

De forma geral, o pipeline de dados idealizado para este projeto contempla as seguintes etapas: (i) coleta e integração das tabelas da base Olist; (ii) análise exploratória e limpeza dos dados; (iii) construção da matriz de interações entre clientes e produtos a partir do histórico de pedidos e avaliações; (iv) treinamento de um modelo de recomendação baseado em filtragem colaborativa; e (v) avaliação do modelo por meio de métricas de acurácia e de distribuição das recomendações entre vendedores de diferentes portes. Essas etapas serão detalhadas ao longo do desenvolvimento do projeto, nas fases de Definição do Produto e Metodologia.

2 CRONOGRAMA DO PROJETO

O cronograma a seguir apresenta a distribuição das atividades do projeto ao longo do semestre, contemplando as quatro etapas definidas pelo componente curricular e as respectivas datas de entrega.

Etapas	Atividade	Período previsto
Etapa 1 – Concepção/Definição do projeto	Reuniões (professor e grupo)	Agosto/2026
Etapa 1 – Concepção/Definição do projeto	Descrição do projeto (tema, base de dados, cronograma)	Agosto/2026
Entrega 1	Capa, Sumário parcial e Introdução	Início de setembro/2026
Etapa 2 – Definição Analítica	Análise exploratória da base de dados	1ª quinzena de setembro/2026
Etapa 2 – Definição Analítica	Tratamento (limpeza e preparação) da base de dados	2ª quinzena de setembro/2026
Etapa 2 – Definição Analítica	Definição e descrição das bases teóricas	Final de setembro/2026
Etapa 2 – Definição Analítica	Treinamento do modelo (prova de conceito), definição e descrição	Final de setembro/início de outubro de 2026
Entrega 2	Análise exploratória, preparação da base e prova de conceito	Início de outubro/2026
Etapa 3 – Metodologia	Descrição da metodologia aplicada e organização das técnicas	Outubro/2026
Etapa 3 – Metodologia	Análise, ajustes e reavaliação do modelo	Outubro/2026
Entrega 3	Metodologia consolidada	Final de outubro/2026
Etapa 4 – Finalização	Organização e análise dos resultados	Final de outubro/início de novembro de 2026
Entrega 4	Resultados, conclusão e trabalhos futuros	Novembro/2026

Nota: os períodos indicados são estimativas planejadas pelo grupo e serão ajustados conforme o calendário oficial da Disciplina

3 REFERENCIAL TEÓRICO

Esta seção apresenta os conceitos que fundamentam as decisões tomadas na Etapa 2 do projeto: o tipo de problema de recomendação enfrentado, as técnicas escolhidas para a prova de conceito, as dificuldades típicas da base utilizada e a forma de avaliar o desempenho do modelo. Ao final, são descritas as bibliotecas Python empregadas.

3.1 Sistemas de recomendação

Sistemas de recomendação são técnicas e ferramentas de software que sugerem itens potencialmente úteis a um usuário, apoiando a tomada de decisão em ambientes com um número de opções maior do que alguém consegue avaliar sozinho (RICCI; ROKACH; SHAPIRA, 2022). No comércio eletrônico, esses sistemas ajudam a transformar visitantes em compradores, a aumentar a venda cruzada e a fidelizar clientes, a partir de dados como histórico de compras e comportamento de outros consumidores (SCHAFFER; KONSTAN; RIEDL, 2001).

De modo geral, as abordagens se dividem em três famílias: a filtragem colaborativa, que usa o comportamento coletivo dos usuários; a filtragem baseada em conteúdo, que usa os atributos dos itens; e os sistemas híbridos, que combinam as duas (GOOGLE, 2023; RICCI; ROKACH; SHAPIRA, 2022). O modelo proposto neste projeto pertence à terceira família, conforme justificado nas seções seguintes.

3.2 Feedback explícito e feedback implícito

Os dados de entrada de um recomendador podem ser de dois tipos. O feedback explícito corresponde a avaliações dadas pelo próprio usuário, como notas de 1 a 5. Já o feedback implícito é inferido do comportamento, como compras, cliques ou visualizações. Em feedback implícito, a ausência de interação é ambígua: o usuário pode não ter gostado do item ou simplesmente nunca ter sido exposto a ele, de modo que só é possível afirmar com alguma segurança o sinal positivo (HU; KOREN; VOLINSKY, 2008).

Na base da Olist, o sinal mais abundante é a compra, e as notas existem apenas para parte dos pedidos e refletem também a experiência logística. Por isso, este trabalho trata a compra como interação positiva (feedback implícito binário) e utiliza a nota apenas como filtro, descartando compras avaliadas com 1 ou 2, que indicam insatisfação.

3.3 Filtragem colaborativa baseada em itens

A filtragem colaborativa parte da premissa de que usuários com comportamentos passados semelhantes tendem a ter gostos semelhantes no futuro. Na variante baseada em itens, a similaridade é calculada entre produtos, a partir de quem os comprou, e a recomendação consiste em sugerir itens parecidos com aqueles que o usuário já consumiu, ideia popularizada pela expressão "quem comprou X também comprou Y" (SARWAR et al., 2001).

A medida de similaridade usual é o cosseno entre os vetores de compradores de cada par de itens. Quando a base é muito esparsa, pares apoiados por pouquíssimas co-compras geram similaridades pouco confiáveis; uma prática comum é aplicar um termo de regularização (*shrinkage*) que reduz o peso desses pares (KOREN; BELL, 2015). Essa é a técnica usada no componente Item-kNN do modelo inicial.

3.4 Fatoração matricial e ALS para feedback implícito

A fatoração matricial representa usuários e itens como vetores em um espaço de fatores latentes de baixa dimensão, de modo que o produto escalar entre o vetor do usuário e o do item estime o quanto aquele item é adequado para aquele usuário (KOREN; BELL; VOLINSKY, 2009). Esses fatores capturam padrões que não são observáveis diretamente, como afinidades entre grupos de produtos.

Para feedback implícito, Hu, Koren e Volinsky (2008) propõem um modelo em que toda interação observada recebe preferência igual a 1, mas com um nível de confiança que cresce com a intensidade do comportamento ($c = 1 + \alpha \cdot r$). Os fatores são aprendidos pelo método dos mínimos quadrados alternados (ALS, do inglês *Alternating Least Squares*): fixam-se os fatores dos itens para resolver os dos usuários de forma exata e, em seguida, faz-se o inverso, repetindo-se o processo por algumas iterações. Os principais hiperparâmetros são o número de fatores, a regularização e o parâmetro α de confiança.

3.5 Filtragem baseada em conteúdo

Na filtragem baseada em conteúdo, cada item é descrito por atributos (categoria, preço, peso, texto etc.) e o perfil do usuário é construído a partir dos atributos dos itens com os quais ele interagiu. A recomendação sugere itens cujos atributos sejam semelhantes ao perfil, geralmente medidos pelo cosseno (LOPS; DE GEMMIS; SEMERARO, 2011). Sua principal vantagem é conseguir recomendar itens novos, que ainda não têm histórico de compras, e sua principal limitação é a tendência de recomendar apenas o que é muito parecido com o já

consumido. Como a base da Olist não traz nome nem descrição dos produtos, o conteúdo disponível se restringe a categoria, faixa de preço e faixa de peso.

3.6 Sistemas híbridos

Sistemas híbridos combinam duas ou mais técnicas para compensar as fraquezas de cada uma (BURKE, 2002). Entre as formas de combinação, a híbrida ponderada soma as pontuações produzidas por cada componente, cada uma multiplicada por um peso. Essa foi a opção adotada no projeto: o modelo soma a popularidade, o Item-kNN, o ALS e o componente de conteúdo, com os scores normalizados e os pesos escolhidos em um conjunto de validação separado do conjunto de teste.

3.7 Desafios: esparsidade, partida-fria e viés de popularidade

Três problemas clássicos da área aparecem de forma intensa na base escolhida. O primeiro é a esparsidade: a matriz usuário×produto tem quase todas as células vazias, o que dificulta encontrar padrões de similaridade (KOREN; BELL; VOLINSKY, 2009). O segundo é a partida-fria (*cold start*), que ocorre quando há usuários ou produtos novos sem histórico suficiente para que a filtragem colaborativa funcione (SCHEIN et al., 2002). O terceiro é o viés de popularidade: como poucos itens concentram a maior parte das interações, os algoritmos tendem a recomendá-los repetidamente, deixando de fora a chamada cauda longa de produtos pouco vendidos (ANDERSON, 2006).

Esse último ponto se conecta diretamente à motivação do projeto, pois pequenos vendedores tendem a estar justamente na cauda longa. Por esse motivo, a popularidade é mantida no modelo como linha de base de comparação, e não apenas como componente.

3.8 Avaliação de sistemas de recomendação

Em vez de prever a nota exata de um item, o objetivo prático de um recomendador de compras é ordenar o catálogo de modo que os itens relevantes apareçam no topo da lista. A avaliação adequada, portanto, é feita por métricas de ranqueamento (SHANI; GUNAWARDANA, 2011). Neste trabalho, utiliza-se o protocolo *leave-one-out* temporal: para cada usuário com ao menos dois produtos distintos, o último produto comprado é retirado do treino e usado como alvo, e verifica-se em que posição o modelo o coloca no ranking.

As métricas adotadas são: a taxa de acerto (*Hit Rate*, $HR@K$), que indica a proporção de usuários cujo item-alvo aparece entre as K primeiras recomendações; o $NDCG@K$

(*Normalized Discounted Cumulative Gain*), que também mede o acerto, mas atribui mais valor às posições mais altas da lista (JÄRVELIN; KEKÄLÄINEN, 2002); e o MRR (*Mean Reciprocal Rank*), média do inverso da posição do item-alvo. Além da acurácia, são acompanhadas a cobertura do catálogo e a popularidade média dos itens recomendados, que indicam diversidade e viés de popularidade (SHANI; GUNAWARDANA, 2011). Para quantificar a incerteza dos resultados, calculam-se intervalos de confiança de 95% por *bootstrap* (EFRON; TIBSHIRANI, 1993).

3.9 Equidade e exposição de vendedores

Em marketplaces, o recomendador atende a mais de um público ao mesmo tempo: os consumidores, que desejam itens relevantes, e os vendedores, que desejam visibilidade. A literatura sobre equidade em sistemas de recomendação (*multisided fairness*) discute como medir e equilibrar o benefício entre esses grupos (BURKE, 2017). Nesta etapa, a cobertura do catálogo e a popularidade média das recomendações funcionam como indicadores iniciais de exposição; na etapa de metodologia, pretende-se analisar a distribuição das recomendações por porte de vendedor, conforme previsto nos objetivos do projeto.

3.10 Bibliotecas Python utilizadas

O desenvolvimento foi realizado em Python com bibliotecas amplamente adotadas em ciência de dados. O NumPy fornece as estruturas e operações de arrays numéricos (HARRIS et al., 2020), e o pandas, a manipulação de dados tabulares (MCKINNEY, 2010). O SciPy oferece as matrizes esparsas, essenciais para representar a matriz usuário×produto sem armazenar milhões de zeros (VIRTANEN et al., 2020). O scikit-learn é usado para o pré-processamento, como a normalização dos vetores de atributos (PEDREGOSA et al., 2011). Por fim, Matplotlib (HUNTER, 2007) e seaborn (WASKOM, 2021) geram os gráficos da análise exploratória e dos resultados. O algoritmo ALS foi implementado diretamente em NumPy, para que a prova de conceito não dependa de pacotes específicos de recomendação.

REFERÊNCIAS

- GOOGLE INC. Recommendation Systems. Machine Learning, 2023. Disponível em: <https://developers.google.com/machine-learning/recommendation>. Acesso em: 25 maio 2023.
- KOREN, Y.; BELL, R.; VOLINSKY, C. Matrix Factorization Techniques for Recommender Systems. *Computer*, v. 42, n. 8, p. 30-37, 2009.
- OLIST. Brazilian E-Commerce Public Dataset by Olist. Kaggle, 2018. Disponível em: <https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce>. Acesso em: 4 set. 2026.
- ONU BRASIL. Objetivos de Desenvolvimento Sustentável. 2023. Disponível em: <https://brasil.un.org/pt-br/sdgs>. Acesso em: 25 maio 2023.
- RICCI, F.; ROKACH, L.; SHAPIRA, B. Recommender Systems Handbook. 3. ed. New York: Springer, 2022.
- SCHAFER, J. B.; KONSTAN, J. A.; RIEDL, J. E-Commerce Recommendation Applications. *Data Mining and Knowledge Discovery*, v. 5, n. 1/2, p. 115-153, 2001.
- ANDERSON, C. The Long Tail: why the future of business is selling less of more. New York: Hyperion, 2006.
- BURKE, R. Hybrid Recommender Systems: Survey and Experiments. *User Modeling and User-Adapted Interaction*, v. 12, n. 4, p. 331-370, 2002.
- BURKE, R. Multisided Fairness for Recommendation. arXiv, 2017. Disponível em: <https://arxiv.org/abs/1707.00093>.
- EFRON, B.; TIBSHIRANI, R. J. An Introduction to the Bootstrap. New York: Chapman & Hall, 1993.
- GOOGLE INC. Recommendation Systems. Machine Learning, 2023. Disponível em: <https://developers.google.com/machine-learning/recommendation>. Acesso em: 25 maio 2023.
- HARRIS, C. R. et al. Array programming with NumPy. *Nature*, v. 585, p. 357-362, 2020.
- HU, Y.; KOREN, Y.; VOLINSKY, C. Collaborative Filtering for Implicit Feedback Datasets. In: IEEE INTERNATIONAL CONFERENCE ON DATA MINING (ICDM), 8., 2008, Pisa. Proceedings [...]. Piscataway: IEEE, 2008. p. 263-272.
- HUNTER, J. D. Matplotlib: A 2D Graphics Environment. *Computing in Science & Engineering*, v. 9, n. 3, p. 90-95, 2007.
- JÄRVELIN, K.; KEKÄLÄINEN, J. Cumulated Gain-Based Evaluation of IR Techniques. *ACM Transactions on Information Systems*, v. 20, n. 4, p. 422-446, 2002.
- KOREN, Y.; BELL, R. Advances in Collaborative Filtering. In: RICCI, F.; ROKACH, L.; SHAPIRA, B. (org.). Recommender Systems Handbook. 2. ed. New York: Springer, 2015. p. 77-118.

KOREN, Y.; BELL, R.; VOLINSKY, C. Matrix Factorization Techniques for Recommender Systems. *Computer*, v. 42, n. 8, p. 30-37, 2009.

LOPS, P.; DE GEMMIS, M.; SEMERARO, G. Content-based Recommender Systems: State of the Art and Trends. In: RICCI, F. et al. (org.). *Recommender Systems Handbook*. New York: Springer, 2011. p. 73-105.

MCKINNEY, W. Data Structures for Statistical Computing in Python. In: *PYTHON IN SCIENCE CONFERENCE (SCIPY)*, 9., 2010, Austin. *Proceedings [...]*. 2010. p. 56-61.

OLIST. Brazilian E-Commerce Public Dataset by Olist. Kaggle, 2018. Disponível em: <https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce>. Acesso em: 4 set. 2026.

PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, v. 12, p. 2825-2830, 2011.

RICCI, F.; ROKACH, L.; SHAPIRA, B. *Recommender Systems Handbook*. 3. ed. New York: Springer, 2022.

SARWAR, B. et al. Item-based Collaborative Filtering Recommendation Algorithms. In: *INTERNATIONAL CONFERENCE ON WORLD WIDE WEB (WWW)*, 10., 2001, Hong Kong. *Proceedings [...]*. New York: ACM, 2001. p. 285-295.

SCHAFER, J. B.; KONSTAN, J. A.; RIEDL, J. E-Commerce Recommendation Applications. *Data Mining and Knowledge Discovery*, v. 5, n. 1/2, p. 115-153, 2001.

SCHEIN, A. I. et al. Methods and Metrics for Cold-Start Recommendations. In: *ACM SIGIR CONFERENCE ON RESEARCH AND DEVELOPMENT IN INFORMATION RETRIEVAL*, 25., 2002, Tampere. *Proceedings [...]*. New York: ACM, 2002. p. 253-260.

SHANI, G.; GUNAWARDANA, A. Evaluating Recommendation Systems. In: RICCI, F. et al. (org.). *Recommender Systems Handbook*. New York: Springer, 2011. p. 257-297.

VIRTANEN, P. et al. SciPy 1.0: fundamental algorithms for scientific computing in Python. *Nature Methods*, v. 17, p. 261-272, 2020.

WASKOM, M. L. seaborn: statistical data visualization. *Journal of Open Source Software*, v. 6, n. 60, p. 3021, 2021.